

بِسْمِ اللَّهِ الرَّحْمَنِ الرَّحِيمِ

طراحی و پیاده سازی یک سامانه هوشمند برای تطبیق، تنقیح و تحلیل قوانین فارسی با استفاده از مدل های زبانی بزرگ

نام دانشجو:	علی دهقان زاده
شماره دانشجویی:	۸۱۰۱۰۱۴۲۳
نام درس / استاد:	استاد هشام فیلی

تعهدنامه اصالت اثر

باسمه تعالی

اینجانب علی دهقان زاده تأیید می کنم که مطالب مندرج در این پایان نامه حاصل تلاش اینجانب است و به دستاوردهای پژوهشی دیگران که در این نوشته از آنها استفاده شده است مطابق مقررات ارجاع گردیده است. این پایان نامه قبلاً برای احراز هیچ مدرک هم سطح یا بالاتر ارائه نشده است.

کلیه حقوق مادی و معنوی این اثر متعلق به دانشکده فنی دانشگاه تهران می باشد.

نام و نام خانوادگی دانشجو : علی دهقان زاده

امضای دانشجو :

تقدیم به مادر که همیشه کنارم بوده

فهرست مطالب

۱.	فصل اول: مقدمه
۱/۱.	بیان مسئله
۱/۲.	هدف تحقیق
۱/۳.	ساختار پایان نامه
۲.	فصل دوم: مقدمه ای بر بعضی مفاهیم
۲/۱.	مقدمه
۲/۲.	پردازش زبان طبیعی و مدل های زبانی
۲/۲/۱.	مدل های زبانی
۲/۲/۲.	مدل های زبانی بزرگ
۲/۲/۳.	پردازش زبان طبیعی در متون حقوقی
۲/۳.	بازیابی اطلاعات از متون حقوقی
۲/۳/۱.	بازیابی واژگانی با روش BM25
۲/۳/۲.	جست و جوی معنایی و بردارهای تعبیه شده
۲/۳/۳.	بازیابی ترکیبی
۲/۳/۴.	بازرتبه بندی نتایج
۲/۴.	تولید تقویت شده با بازیابی
۳.	فصل سوم: طراحی سامانه
۳/۱.	معماری سامانه
۳/۲.	معماری ساختار داده های حقوقی
۳/۳.	معماری قسمت بازیابی اطلاعات
۳/۴.	معماری قسمت تولید پاسخ مبتنی بر بازیابی
۴.	فصل چهارم: پیاده سازی سامانه پاسخ گویی هوشمند حقوقی
۴/۱.	پیاده سازی ساختار داده های حقوقی
۴/۲.	پیاده سازی فرآیند پردازش و آماده سازی داده ها
۴/۳.	پیاده سازی موتور بازیابی اطلاعات
۴/۴.	پیاده سازی مرحله بازرتبه بندی نتایج
۴/۵.	پیاده سازی ماژول تولید پاسخ
۵.	فصل پنجم: جمع بندی
۵/۱.	نتیجه گیری
۵/۲.	محدودیت ها
۶.	منابع و مراجع

۱. مقدمه

۱-۱. بیان مسئله

یکی از مهم‌ترین مسائل پیش روی نظام‌های اطلاعات حقوقی، نبود ابزارهای کارآمد برای بازیابی و تحلیل داده‌های حقوقی در قالبی است که هم از نظر دقت، هم از نظر سرعت و هم از نظر قابلیت استناد پاسخ‌گویی، قابل قبول باشد. بررسی‌های موجود نشان می‌دهد که اکثر روش‌های جست‌وجو و بازیابی اطلاعات، تنها به تطبیق کلمات کلیدی محدود می‌شوند و در مواجهه با پرسش‌های پیچیده حقوقی، قادر به ارائه پاسخ‌های دقیق و مستند نیستند. در نتیجه، یافتن پاسخ درست به پرسش‌های حقوقی، به‌ویژه با توجه به ساختار مشخص قوانین، بخش‌ها، تبصره‌ها و نسخه‌های مختلف مقررات، نیازمند یک سیستم هوشمند است.

پرسش‌های حقوقی معمولاً با پیچیدگی‌های خاصی همراه هستند؛ از جمله وجود رابطه میان احکام مختلف، تفاوت میان نسخه‌های جاری و قدیمی یک ماده یا مقرره، و لزوم استناد به مدارک معتبر و مراجع قانونی. در چنین شرایطی، یک سیستم صرفاً مبتنی بر جست‌وجوی کلمه‌محور، نمی‌تواند پاسخ‌های دقیق و قابل اعتمادی ارائه دهد. از این رو، مسئله اصلی تحقیق، طراحی یک سیستم هوشمند است که بتواند با درک ساختار اسناد حقوقی، نسبت به بازیابی ده‌ها و حتی صدها سند مرتبط اقدام کرده و بر اساس آن‌ها، پاسخ‌هایی شبیه به پاسخ‌های حقوقی معتبر و کارشناسانه ارائه دهد.

در پروژه حاضر، داده‌های حقوقی به‌صورت ساختارمند و طبق مدل‌های مختلف اسناد، عناصر و مقررات در پایگاه داده نگهداری می‌شوند. این ساختار به سیستم اجازه می‌دهد که در کنار استخراج متن، به بخش‌ها، مواد، تبصره‌ها و ریشه‌های قوانین نیز دسترسی پیدا کند. از طرفی، وجود سرویس‌های جانبی مانند Milvus برای جست‌وجوی برداری، و موتورهای رترووال مبتنی بر متن، امکان ترکیب روش‌های مختلف بازیابی اطلاعات را فراهم می‌کند. این رویکرد، در مقایسه با روش‌های سنتی، به‌طور قابل‌توجهی دقت و کیفیت پاسخ‌هایی را که به کاربر ارائه می‌شود، افزایش می‌دهد.

۱-۲. هدف تحقیق

هدف اصلی این تحقیق، طراحی و پیاده‌سازی یک سامانه پاسخ‌گویی هوشمند به پرسش‌های حقوقی است که بتواند:

- اسناد و مقررات حقوقی را از منابع مختلف جمع‌آوری و ساختاردهی کند.
- به‌صورت مؤثر، اطلاعات مرتبط با پرسش کاربر را بازیابی نماید.
- پاسخ‌های حقوقی را بر اساس مدارک معتبر و منابع موجود ارائه دهد.
- در کنار ارائه پاسخ، استنادات لازم را به متن و ماده‌های مرتبط اعمال کند.
- برای کاربر، تجربه‌ای کاربرپسند و قابل‌اعتماد در زمینه پرسش و پاسخ حقوقی ایجاد نماید.

از اهداف فرعی می‌توان به استخراج و نگهداری روابط بین اسناد، شناسایی نسخه‌های مختلف یک ماده، و ترکیب روش‌های مبتنی بر جست‌وجوی معنایی و کلمه‌ای اشاره کرد. همچنین، یکی از اهداف مهم، افزایش قابلیت اطمینان سیستم در پاسخ‌گویی به سؤالاتی است که در این حوزه، داده‌های کافی برای پاسخ‌گویی ندارند؛ به‌طوری که سیستم به‌جای ارائه پاسخ نادرست، به‌صورت روشن اعلام کند که اطلاعات کافی وجود ندارد.

۳-۱. ساختار گزارش

این گزارش در شش فصل تنظیم شده است. در فصل اول، مسئله، اهداف و کلیات پروژه بیان می‌شود. فصل دوم به معرفی مفاهیم و روش‌های مرتبط با پردازش زبان طبیعی، بازیابی اطلاعات و مدل‌های زبانی اختصاص دارد. در فصل سوم، معماری و طراحی سامانه ارائه می‌شود. فصل چهارم به نحوه پیاده‌سازی اجزای مختلف سامانه می‌پردازد. در فصل پنجم، نتیجه‌گیری و محدودیت‌های پروژه بررسی می‌شوند. در نهایت، فصل ششم شامل منابع و مراجع مورد استفاده در این پروژه است.

فصل ۲: مفاهیم پایه و پیش‌زمینه

۲-۱. مقدمه

در سال‌های اخیر، پیشرفت روش‌های هوش مصنوعی و پردازش زبان طبیعی، امکان پردازش و تحلیل حجم زیادی از داده‌های متنی را فراهم کرده است. در میان انواع داده‌های متنی، اسناد حقوقی به دلیل ساختار پیچیده، حجم بالا، وجود اصطلاحات تخصصی و اهمیت دقت و استناد، یکی از حوزه‌هایی هستند که استفاده از روش‌های هوشمند در آن‌ها اهمیت ویژه‌ای دارد.

سامانه‌های حقوقی هوشمند می‌توانند با استفاده از روش‌هایی مانند پردازش زبان طبیعی، مدل‌های زبانی، بازیابی اطلاعات و تولید متن، بخشی از فرایند جست‌وجو و تحلیل اسناد حقوقی را خودکار کنند. با این حال، استفاده از مدل‌های زبانی به‌تنهایی برای این منظور کافی نیست؛ زیرا پاسخ تولیدشده باید بر اساس منابع حقوقی معتبر باشد و امکان شناسایی و ارائه مستندات مرتبط نیز وجود داشته باشد.

در این فصل، مفاهیم و فناوری‌های مورد استفاده در طراحی سامانه حاضر بررسی می‌شوند. ابتدا مفاهیم مرتبط با پردازش زبان طبیعی و مدل‌های زبانی معرفی شده و سپس مفاهیم مربوط به بازیابی اطلاعات، جست‌وجوی معنایی، بازرتبه‌بندی و تولید تقویت‌شده با بازیابی بررسی خواهند شد. این مفاهیم، مبنای نظری معماری سامانه پیشنهادی در فصل‌های بعدی را تشکیل می‌دهند.

۲-۲. پردازش زبان طبیعی و مدل‌های زبانی

پردازش زبان طبیعی (Natural Language Processing یا NLP) یکی از شاخه‌های هوش مصنوعی است که به مطالعه و توسعه روش‌هایی برای پردازش، تحلیل و تولید زبان انسان توسط رایانه می‌پردازد. هدف اصلی این

حوزه، ایجاد امکان تعامل مؤثر میان انسان و سامانه‌های رایانه‌ای از طریق زبان طبیعی و استخراج اطلاعات و معنا از متون و گفتار است.

متون زبان طبیعی برخلاف داده‌های ساختاریافته، دارای ساختار صریح و ثابتی نیستند و یک مفهوم واحد می‌تواند با استفاده از عبارت‌ها و کلمات متفاوت بیان شود. برای مثال، در یک پرسش حقوقی ممکن است کاربر مفهوم مشخصی را با واژه‌هایی بیان کند که عیناً در متن قانون وجود ندارند. بنابراین، سامانه‌های پردازش زبان طبیعی باید بتوانند علاوه بر تطبیق واژه‌ها، تا حد امکان ارتباط معنایی میان عبارات را نیز در نظر بگیرند.

از کاربردهای مهم پردازش زبان طبیعی می‌توان به دسته‌بندی متون، استخراج اطلاعات، تشخیص موجودیت‌های نامدار، تحلیل معنایی، ترجمه ماشینی، پاسخ‌گویی به پرسش‌ها و بازیابی اطلاعات اشاره کرد. در حوزه حقوق نیز این روش‌ها برای پردازش قوانین، قراردادهای، آرای قضایی و سایر اسناد حقوقی مورد استفاده قرار می‌گیرند.

۲-۲-۱. مدل‌های زبانی

مدل زبانی (Language Model) مدلی است که با استفاده از الگوهای موجود در داده‌های متنی، احتمال وقوع توالی‌های مختلف از کلمات یا توکن‌ها را یاد می‌گیرد. به بیان ساده، مدل زبانی می‌تواند بر اساس متن مشاهده‌شده، احتمال ادامه یا ارتباط بخش‌های مختلف یک متن را تخمین بزند.

مدل‌های زبانی اولیه عمدتاً بر اساس روش‌های آماری و احتمال وقوع کلمات در کنار یکدیگر ساخته می‌شدند. با پیشرفت یادگیری عمیق، شبکه‌های عصبی جایگزین بسیاری از این روش‌ها شدند و مدل‌هایی با قابلیت درک بهتر وابستگی‌های موجود در متن توسعه یافتند.

یکی از مراحل مهم در توسعه مدل‌های زبانی، استفاده از معماری Transformer است. این معماری با استفاده از سازوکار Attention امکان بررسی ارتباط میان بخش‌های مختلف یک متن را فراهم می‌کند و در مقایسه با بسیاری از روش‌های پیشین، توانایی بهتری در پردازش وابستگی‌های دور در متن دارد.

۲-۲-۲. مدل‌های زبانی بزرگ

مدل‌های زبانی بزرگ (Large Language Models یا LLMs) دسته‌ای از مدل‌های زبانی هستند که با استفاده از حجم بسیار زیادی از داده‌های متنی و تعداد زیادی پارامتر آموزش داده می‌شوند. افزایش مقیاس مدل و داده‌های آموزشی باعث شده است این مدل‌ها بتوانند وظایف متنوعی مانند تولید متن، پاسخ‌گویی به پرسش‌ها، خلاصه‌سازی، استخراج اطلاعات و تحلیل متون را انجام دهند.

مدل‌های زبانی بزرگ معمولاً ابتدا طی فرایند پیش‌آموزش (Pre-training) بر روی حجم زیادی از متن آموزش داده می‌شوند. در این مرحله، مدل با مشاهده نمونه‌های مختلف زبان، الگوهای زبانی و ارتباط میان توکن‌ها را یاد می‌گیرد. پس از آن، می‌توان مدل را برای کاربردهای خاص، از جمله پاسخ‌گویی به پرسش یا پردازش متون تخصصی، مورد استفاده یا تنظیم قرار داد.

با وجود قابلیت‌های گسترده، مدل‌های زبانی بزرگ محدودیت‌هایی نیز دارند. یکی از مهم‌ترین این محدودیت‌ها، امکان تولید اطلاعات نادرست یا غیرمستند است. این مسئله در حوزه حقوق اهمیت بیشتری دارد، زیرا یک پاسخ ظاهراً صحیح اما فاقد مبنای قانونی می‌تواند قابل اعتماد نباشد. به همین دلیل، در سامانه‌های حقوقی بهتر است تولید پاسخ به اطلاعات موجود در منابع حقوقی معتبر متصل شود.

۲-۲-۳. پردازش زبان طبیعی در متون حقوقی

متون حقوقی ویژگی‌هایی دارند که پردازش آن‌ها را نسبت به متون عمومی دشوارتر می‌کند. استفاده از اصطلاحات تخصصی، ساختار سلسله‌مراتبی قوانین، وابستگی میان مواد و تبصره‌ها، ارجاع به سایر اسناد و وجود نسخه‌های مختلف یک مقررہ از جمله این ویژگی‌ها هستند.

علاوه بر این، در متون حقوقی تفاوت میان دو عبارت ظاهراً مشابه ممکن است از نظر حقوقی اهمیت زیادی داشته باشد. بنابراین، سامانه حقوقی باید بتواند علاوه بر پردازش محتوای متنی، ساختار و اطلاعات مرتبط با هر بخش از سند را نیز در نظر بگیرد.

در زبان فارسی نیز چالش‌هایی مانند تنوع نوشتاری، شکل‌های مختلف فاصله و نیم‌فاصله، وجود نویسه‌های متفاوت برای برخی حروف و پیچیدگی ساختاری متون می‌تواند بر عملکرد روش‌های پردازش زبان طبیعی تأثیر بگذارد. از این رو، پیش‌پردازش و نرمال‌سازی مناسب متن و استفاده از مدل‌هایی که توانایی پردازش زبان فارسی را دارند، از عوامل مهم در طراحی سامانه‌های حقوقی فارسی محسوب می‌شوند.

در سامانه حاضر، پردازش زبان طبیعی و مدل‌های زبانی به عنوان بخش‌هایی از زنجیره پردازش پرسش و تولید پاسخ مورد استفاده قرار می‌گیرند. با این حال، به منظور کاهش وابستگی پاسخ به دانش ذخیره‌شده در خود مدل زبانی، اطلاعات حقوقی مرتبط ابتدا از پایگاه داده بازیابی شده و سپس در اختیار مدل زبانی قرار می‌گیرد. این فرایند در ادامه و در بخش مربوط به روش RAG بررسی خواهد شد.

۲-۳. بازیابی اطلاعات در متون حقوقی

بازیابی اطلاعات (Information Retrieval یا IR) به مجموعه روش‌ها و فناوری‌هایی گفته می‌شود که با هدف یافتن اطلاعات مرتبط با یک پرسش از میان مجموعه‌ای از اسناد یا داده‌ها به کار می‌روند. در سامانه‌های مبتنی بر متن، بازیابی اطلاعات معمولاً نخستین مرحله برای محدود کردن حجم زیادی از اطلاعات و یافتن اسناد مرتبط با نیاز کاربر است.

در یک سامانه حقوقی، اهمیت بازیابی اطلاعات بیشتر است؛ زیرا حجم اسناد و مقررات می‌تواند بسیار زیاد باشد و پاسخ به یک پرسش ممکن است به یک ماده یا مجموعه‌ای از مواد قانونی وابسته باشد. در چنین شرایطی، جست‌وجوی ساده بر اساس تطبیق کلمات کلیدی همیشه نمی‌تواند مناسب‌ترین مواد را پیدا کند. برای مثال،

ممکن است کاربر یک مفهوم حقوقی را با عبارتی بیان کند که عیناً در متن قانون وجود ندارد. بنابراین، استفاده از روش‌های مختلف بازیابی می‌تواند دقت سامانه را افزایش دهد.

۱-۳-۲. بازیابی واژگانی با روش BM25

یکی از روش‌های متداول در بازیابی اطلاعات، جست‌وجوی واژگانی است. در این روش، ارتباط میان پرسش و سند بر اساس حضور و اهمیت واژه‌های موجود در آن‌ها تعیین می‌شود. یکی از الگوریتم‌های شناخته‌شده در این زمینه BM25 است.

BM25 میزان ارتباط یک سند با پرسش را بر اساس عواملی مانند تعداد تکرار واژه‌های پرسش در سند، میزان نادر یا رایج بودن واژه در مجموعه اسناد و طول سند محاسبه می‌کند. در نتیجه، واژه‌هایی که در اسناد مرتبط با یک پرسش اهمیت بیشتری دارند، تأثیر بیشتری بر امتیاز نهایی خواهند داشت.

یکی از مزیت‌های اصلی BM25، عملکرد مناسب آن در جست‌وجوی دقیق واژه‌ها و اصطلاحات است. این ویژگی در متون حقوقی اهمیت دارد؛ زیرا شماره ماده، نام قانون و بسیاری از اصطلاحات حقوقی می‌توانند اطلاعات بسیار مشخصی درباره سند موردنظر ارائه کنند. با این حال، BM25 در تشخیص شباهت معنایی میان عبارت‌هایی که از واژه‌های متفاوتی برای بیان یک مفهوم استفاده می‌کنند، محدودیت دارد.

۲-۳-۲. جست‌وجوی معنایی و بردارهای تعبیه‌شده

برای برطرف کردن بخشی از محدودیت‌های جست‌وجوی واژگانی، می‌توان از جست‌وجوی معنایی (Semantic Search) استفاده کرد. در این روش، متن به یک نمایش عددی با نام بردار تعبیه‌شده (Embedding) تبدیل می‌شود. این بردار ویژگی‌های معنایی متن را در فضای عددی نمایش می‌دهد.

در جست‌وجوی معنایی، ابتدا پرسش کاربر به یک بردار تبدیل شده و سپس میزان شباهت آن با بردارهای مربوط به اسناد محاسبه می‌شود. در نتیجه، اسنادی که از نظر معنایی به پرسش نزدیک‌تر هستند می‌توانند حتی در صورت نداشتن کلمات کاملاً یکسان، به عنوان نتایج مرتبط بازیابی شوند.

در سامانه حاضر، برای ایجاد نمایش برداری از متون حقوقی از یک مدل embedding مناسب زبان فارسی استفاده شده و بردارهای حاصل در یک پایگاه داده برداری ذخیره می‌شوند. این روش امکان جست‌وجوی سریع میان تعداد زیادی از مقررات و مواد قانونی را فراهم می‌کند.

۳-۳-۲. بازیابی ترکیبی

هر یک از روش‌های واژگانی و معنایی دارای نقاط قوت و ضعف خاص خود هستند. جست‌وجوی واژگانی در تطبیق دقیق اصطلاحات، نام قوانین و شماره مواد عملکرد مناسبی دارد، در حالی که جست‌وجوی معنایی می‌تواند ارتباط مفهومی میان عبارت‌های متفاوت را تشخیص دهد.

به همین دلیل، در سامانه حاضر از رویکرد بازیابی ترکیبی (Hybrid Retrieval) استفاده شده است. در این روش، نتایج حاصل از BM25 و جستجوی معنایی به صورت مستقل تولید شده و سپس با استفاده از روش Reciprocal Rank Fusion یا RRF با یکدیگر ترکیب می‌شوند.

RRF به جای مقایسه مستقیم امتیازهای دو روش، رتبه هر نتیجه در فهرست مربوط به خود را در نظر می‌گیرد. به این ترتیب، سندی که توسط هر دو روش در رتبه‌های بالا قرار گرفته باشد، امتیاز ترکیبی بیشتری دریافت خواهد کرد.

استفاده از بازیابی ترکیبی باعث می‌شود سامانه بتواند هم از تطبیق دقیق واژه‌ها و هم از شباهت معنایی استفاده کند. این ویژگی به‌خصوص در پرسش‌های حقوقی که ممکن است شامل نام قانون، شماره ماده، اصطلاحات تخصصی یا عبارات مفهومی باشند، اهمیت دارد.

۴-۳-۲. بازرتبه‌بندی نتایج

پس از مرحله بازیابی اولیه، ممکن است تعداد نسبتاً زیادی نتیجه در اختیار سامانه قرار گیرد. با وجود آنکه این نتایج توسط روش‌های بازیابی انتخاب شده‌اند، همه آن‌ها الزاماً به یک اندازه با پرسش کاربر مرتبط نیستند. بنابراین، مرحله دیگری برای ارزیابی دقیق‌تر ارتباط میان پرسش و نتایج بازیابی شده مورد نیاز است.

بازرتبه‌بندی (Reranking) فرایندی است که در آن مجموعه‌ای از نتایج اولیه با استفاده از یک مدل دقیق‌تر دوباره ارزیابی و مرتب می‌شوند. در این مرحله، پرسش کاربر و متن هر نتیجه به صورت یک زوج در اختیار مدل بازرتبه‌بندی قرار می‌گیرند و مدل میزان ارتباط آن‌ها را تعیین می‌کند.

در سامانه حاضر، بازرتبه‌بندی پس از بازیابی ترکیبی انجام می‌شود. ابتدا مجموعه‌ای از نامزدها با استفاده از BM25 و جستجوی معنایی بازیابی شده و سپس مدل بازرتبه‌بندی، ارتباط هر یک از آن‌ها با پرسش را ارزیابی می‌کند. در نهایت، تنها نتایجی که از نظر ارتباط امتیاز مناسبی داشته باشند برای مرحله تولید پاسخ ارسال می‌شوند.

علاوه بر محدود کردن تعداد نتایج، در این مرحله می‌توان از آستانه‌های امتیازی نیز استفاده کرد. یک آستانه مطلق مانع از ورود نتایج زمانی می‌شود که حتی بهترین نتیجه ارتباط کافی با پرسش نداشته باشد. همچنین یک آستانه نسبی می‌تواند نتایجی را که فاصله زیادی با بهترین نتیجه دارند حذف کند. این سازوکار به کاهش ورود اطلاعات نامرتب به مرحله تولید پاسخ کمک می‌کند.

۴-۲. تولید تقویت‌شده با بازیابی

مدل‌های زبانی بزرگ توانایی بالایی در تولید متن و پاسخ‌گویی به پرسش‌ها دارند، اما دانش موجود در آن‌ها لزوماً شامل آخرین نسخه اطلاعات موردنیاز یا منابع مشخص و قابل استناد نیست. همچنین، این مدل‌ها ممکن است در

شرایطی که اطلاعات کافی در اختیار ندارند، پاسخ‌هایی تولید کنند که از نظر زبانی صحیح به نظر می‌رسند اما از نظر factual یا مستند بودن قابل اعتماد نیستند.

تولید تقویت‌شده با بازیابی (Retrieval-Augmented Generation یا RAG) روشی است که برای کاهش این محدودیت مورد استفاده قرار می‌گیرد. در این روش، پیش از تولید پاسخ، اطلاعات مرتبط از یک منبع خارجی بازیابی شده و در اختیار مدل زبانی قرار می‌گیرد. مدل سپس پاسخ خود را بر اساس اطلاعات بازیابی‌شده تولید می‌کند.

این روش برای سامانه‌های حقوقی اهمیت ویژه‌ای دارد؛ زیرا پاسخ حقوقی باید تا حد امکان بر اساس متن قوانین و مقررات موجود باشد و بتوان منبع پاسخ را نیز مشخص کرد.

۳. فصل سوم: طراحی سامانه

۳-۱. معماری سامانه

معماری سامانه پیشنهادی به صورت یک فرایند چندمرحله‌ای طراحی شده است که در آن وظایف پردازش پرسش، بازیابی اطلاعات حقوقی، انتخاب و بازرتبه‌بندی اسناد مرتبط و تولید پاسخ از یکدیگر تفکیک شده‌اند. این تفکیک باعث می‌شود هر بخش از سامانه بتواند وظیفه مشخصی را انجام داده و امکان توسعه و تغییر اجزای مختلف بدون ایجاد وابستگی شدید میان آن‌ها فراهم شود.

در لایه داده، اطلاعات حقوقی در پایگاه داده رابطه‌ای PostgreSQL ذخیره می‌شوند. ساختار داده شامل اسناد حقوقی، عناصر ساختاری و مقررات هر سند است. در این ساختار، هر مقرره می‌تواند به صورت مستقل شناسایی شده و اطلاعاتی مانند شماره، عنوان و متن آن در اختیار سامانه قرار گیرد. این ساختار امکان ارتباط میان متن هر مقرره و سند حقوقی مربوط به آن را فراهم می‌کند.

در لایه بازیابی، دو روش متفاوت برای یافتن اطلاعات مرتبط مورد استفاده قرار گرفته است. روش نخست، بازیابی واژگانی با استفاده از BM25 است که بر اساس میزان تطابق واژه‌های پرسش با متن مقررات عمل می‌کند. روش دوم، بازیابی معنایی است که با استفاده از بردارهای embedding، شباهت معنایی میان پرسش و مقررات را بررسی می‌کند. نتایج حاصل از این دو روش با استفاده از الگوریتم Reciprocal Rank Fusion یا RRF با یکدیگر ترکیب می‌شوند تا مجموعه‌ای از نامزدهای اولیه برای مرحله بعدی ایجاد شود.

پس از مرحله بازیابی اولیه، نتایج توسط یک مدل بازرتبه‌بندی بررسی شده و بر اساس میزان ارتباط مستقیم آن‌ها با پرسش کاربر مرتب می‌شوند. این مرحله باعث می‌شود نتایج نامرتب یا ضعیف که ممکن است در مرحله بازیابی اولیه وارد شده باشند، در اولویت پایین‌تری قرار گیرند.

در مرحله نهایی، نتایج منتخب به وسیله یک Context Builder به یک زمینه حقوقی ساخت‌یافته تبدیل می‌شوند. سپس این زمینه همراه با پرسش کاربر در اختیار مدل زبانی قرار می‌گیرد. مدل زبانی موظف است پاسخ

خود را بر اساس اطلاعات موجود در زمینه تولید کرده و در صورت کافی نبودن اطلاعات بازیابی شده، از ارائه اطلاعات خارج از زمینه خودداری کند.

به این ترتیب، جریان کلی سامانه را می توان به صورت زیر خلاصه کرد:

لایه	مسئولیت	اجزای اصلی
داده	ذخیره پایدار و روابط حقوقی	Django، PostgreSQL، مدل های
آماده سازی	نرمال سازی، طبقه بندی و تبدیل JSON به ساختار حقوقی	Importer، Hazm، دستورات مدیریتی
بازیابی	یافتن مواد مرتبط با پرسش	BM25، Persian Embeddings، Milvus، RRF
دقت نهایی	رتبه بندی مجدد کاندیداها	safora/reranker-xlm-roberta-large
تولید پاسخ	ساخت زمینه و پاسخ JSON کنترل شده	RAG، OpenRouter/OpenAI-compatible client
روابط حقوقی	استخراج ارجاع و اثر اصلاح/نسخه/الحاق	ReferenceExtractor، ActionExtractor

جدول ۱ - لایه های سیستم

۳-۲. معماری ساختار داده های حقوقی

یکی از بخش های اصلی سامانه پیشنهادی، طراحی ساختار مناسب برای ذخیره سازی و سازمان دهی اطلاعات حقوقی است. به دلیل وجود ساختار سلسله مراتبی در اسناد حقوقی، ذخیره سازی متن قوانین به صورت یک مجموعه ساده از رشته های متنی نمی تواند تمام روابط میان سند، بخش های مختلف آن و مقررات را حفظ کند. بنابراین، در این سامانه اطلاعات حقوقی به صورت ساخت یافته در پایگاه داده PostgreSQL ذخیره شده اند.

در بالاترین سطح، موجودیت LegalDocument برای نمایش یک سند حقوقی در نظر گرفته شده است. این موجودیت اطلاعاتی مانند عنوان سند، نوع سند، مرجع صادر کننده، تاریخ تصویب، تاریخ انتشار، تاریخ اجرا و وضعیت سند را نگهداری می کند. هر سند حقوقی می تواند شامل مجموعه ای از عناصر ساختاری و مقررات باشد.

برای حفظ ساختار داخلی اسناد، موجودیت LegalElement طراحی شده است. این موجودیت امکان ایجاد ارتباط سلسله مراتبی میان عناصر مختلف یک سند را فراهم می کند. عناصری مانند کتاب، بخش، فصل، مبحث و سایر بخش های ساختاری سند از طریق این ساختار قابل نمایش هستند. در نتیجه، جایگاه هر قسمت از یک سند در ساختار کلی آن قابل نگهداری است.

در سطح پایین‌تر، موجودیت LegalProvision برای نمایش مقررات حقوقی استفاده می‌شود. هر مقررہ دارای اطلاعاتی مانند نوع مقررہ، شماره، عنوان و متن است و از طریق عنصر ساختاری مربوطه به سند حقوقی متصل می‌شود. این تفکیک باعث می‌شود واحد اصلی مورد استفاده در فرایند بازیابی، یعنی متن یک مقررہ، به صورت مستقل قابل شناسایی و بازیابی باشد.

علاوه بر متن اصلی مقررات، ساختار داده سامانه امکان نگهداری نسخه‌های مختلف یک مقررہ را نیز فراهم می‌کند. موجودیت LegalVersion برای ثبت نسخه‌های مختلف متن یک مقررہ و وضعیت هر نسخه مورد استفاده قرار می‌گیرد. این موضوع در متون حقوقی اهمیت زیادی دارد، زیرا یک مقررہ ممکن است در طول زمان اصلاح یا با نسخه جدیدی جایگزین شده باشد و پاسخ به یک پرسش حقوقی باید تا حد امکان بر اساس نسخه معتبر و مرتبط با زمان مورد نظر کاربر ارائه شود.

همچنین برای نمایش ارتباط میان مقررات، موجودیت LegalRelationship در نظر گرفته شده است. این موجودیت امکان ثبت روابطی مانند اصلاح، نسخ، جایگزینی، ارجاع و سایر روابط میان مقررات را فراهم می‌کند. اطلاعات تکمیلی مربوط به هر رابطه نیز در موجودیت RelationshipContext نگهداری می‌شود. این ساختار در طراحی فعلی سامانه به عنوان زیرساختی برای توسعه قابلیت‌های پیشرفته‌تر تحلیل روابط حقوقی در نظر گرفته شده است.

در نتیجه، ساختار داده‌ای سامانه از چند سطح اصلی تشکیل می‌شود: سند حقوقی، عناصر ساختاری سند، مقررات، نسخه‌های مقررات و روابط میان مقررات. این طراحی علاوه بر حفظ ساختار اصلی اسناد، امکان استفاده مستقیم از مقررات به عنوان واحدهای مستقل در فرایند بازیابی اطلاعات را فراهم می‌کند.

و اطلاعات مربوط به نسخه‌ها و روابط حقوقی در کنار این ساختار اصلی قرار می‌گیرند. این سازمان‌دهی مبنای ذخیره‌سازی اطلاعات در پایگاه داده و همچنین استفاده از مقررات در مراحل بازیابی و تولید پاسخ سامانه است.

موجودیت	کاربرد در سامانه
LegalEntity	هویت یکتای سند یا موجودیت قانونی در سطح مفهومی
LegalDocument	فراداده قانون: عنوان، نوع، مرجع، تاریخ، سلسله‌مراتب و وضعیت
LegalElement / StructuralElement	نگهداری درخت ساختارهایی مانند کتاب، بخش، فصل و قسمت
LegalProvision	واحد قابل استناد: اصل، ماده، تبصره، بند، جزء یا مورد دیگر
LegalVersion	متن و وضعیت نسخه‌های زمانی یک مقررہ
LegalRelationship / RelationshipContext	روابط بین مواد و شواهد مربوط به آن‌ها

جدول ۲ - مدل‌هایی که قوانین فارسی در آنها ذخیره می‌شود.

۳-۳. معماری قسمت بازیابی اطلاعات

بازیابی اطلاعات یکی از اجزای اصلی سامانه پیشنهادی است و وظیفه آن یافتن مقررات حقوقی مرتبط با پرسش کاربر پیش از مرحله تولید پاسخ است. با توجه به ویژگی‌های متون حقوقی فارسی، استفاده از یک روش واحد برای بازیابی اطلاعات نمی‌تواند به تنهایی نیازهای سامانه را پوشش دهد. تطابق واژگانی برای یافتن پرسش‌هایی که شامل عبارات یا شماره‌های مشخص قانونی هستند مناسب است، در حالی که در بسیاری از پرسش‌ها، ارتباط معنایی میان عبارت پرسش و متن مقرر اهمیت بیشتری دارد. به همین دلیل، در سامانه پیشنهادی از ترکیب بازیابی واژگانی و بازیابی معنایی استفاده شده است.

فرایند بازیابی از پردازش و نرمال‌سازی پرسش آغاز می‌شود. در این مرحله، پرسش کاربر پس از بررسی اولیه و حذف فضاهای غیرضروری، با استفاده از ابزارهای پردازش زبان طبیعی نرمال‌سازی می‌شود تا اختلاف‌های نوشتاری موجود در متن فارسی، مانند تفاوت در فاصله‌گذاری و شکل برخی نویسه‌ها، تأثیر کمتری بر فرایند بازیابی داشته باشد.

پس از پردازش پرسش، دو مسیر بازیابی به صورت مستقل اجرا می‌شوند. مسیر نخست از روش BM25 برای بازیابی واژگانی استفاده می‌کند. در این روش، میزان ارتباط هر مقرر با پرسش بر اساس حضور و فراوانی واژه‌های پرسش در متن مقرر محاسبه می‌شود. این روش به‌ویژه برای پرسش‌هایی که شامل شماره ماده، عبارت قانونی مشخص یا واژه‌های تخصصی هستند اهمیت دارد.

در مسیر دوم، پرسش به یک بردار عددی یا embedding تبدیل می‌شود. همچنین برای هر مقرر حقوقی یک embedding از متن آن ایجاد و در پایگاه داده برداری Milvus ذخیره شده است. سپس با محاسبه شباهت میان embedding پرسش و embedding مقررات، مجموعه‌ای از مقررات دارای ارتباط معنایی با پرسش بازیابی می‌شوند. این روش می‌تواند در شرایطی که پرسش کاربر دقیقاً از واژه‌های موجود در متن قانون استفاده نمی‌کند، نسبت به تطابق صرفاً واژگانی عملکرد مناسب‌تری داشته باشد.

نتایج حاصل از دو روش BM25 و بازیابی معنایی سپس با استفاده از روش Reciprocal Rank Fusion یا RRF با یکدیگر ترکیب می‌شوند. در این مرحله، به جای مقایسه مستقیم امتیازهای دو روش که در مقیاس‌های متفاوت قرار دارند، رتبه هر نتیجه در هر فهرست مورد استفاده قرار می‌گیرد. بدین ترتیب، مقرراتی که در هر دو روش رتبه مناسبی کسب کرده‌اند، امتیاز ترکیبی بالاتری دریافت می‌کنند.

پس از ترکیب نتایج، تعدادی از مقررات برتر به مرحله بازرتبه‌بندی ارسال می‌شوند. در این مرحله، مدل Reranker هر جفت شامل پرسش و متن مقرر را به صورت مستقیم بررسی کرده و میزان ارتباط آن‌ها را ارزیابی می‌کند. برخلاف مرحله بازیابی اولیه که برای جست‌وجو در حجم زیادی از داده طراحی شده است،

بازرتبه‌بندی تنها روی تعداد محدودی از نامزدهای بازیابی شده انجام می‌شود و بنابراین می‌تواند تحلیل دقیق‌تری از ارتباط پرسش و مقررده ارائه دهد.

برای جلوگیری از ورود نتایج ضعیف به مرحله تولید پاسخ، در مرحله بازرتبه‌بندی دو شرط در نظر گرفته شده است. ابتدا، در صورتی که امتیاز بهترین نتیجه از یک آستانه مشخص کمتر باشد، نتیجه‌ای به عنوان پاسخ مناسب به مرحله بعد ارسال نمی‌شود. همچنین نتایجی که اختلاف زیادی با بهترین نتیجه داشته باشند حذف می‌شوند. بنابراین تعداد نتایج نهایی ثابت نیست و بر اساس میزان اطمینان حاصل شده از ارتباط نتایج تعیین می‌شود.

این طراحی باعث می‌شود روش‌های مختلف بازیابی نقاط قوت یکدیگر را پوشش دهند BM25. برای تطابق دقیق واژگان و عبارات قانونی مناسب است، بازیابی معنایی امکان شناسایی ارتباط مفهومی میان پرسش و مقررات را فراهم می‌کند و Reranker با بررسی دقیق‌تر زوج پرسش و مقررده، کیفیت رتبه‌بندی نهایی را افزایش می‌دهد.

در نهایت، نتایج تأییدشده توسط این فرایند به بخش تولید پاسخ منتقل می‌شوند و به عنوان مبنای ایجاد زمینه حقوقی مورد استفاده قرار می‌گیرند. در نتیجه، مدل زبانی مستقیماً روی کل مجموعه مقررات حقوقی عمل نمی‌کند، بلکه پاسخ خود را بر اساس مجموعه محدودی از مقررات مرتبط که توسط سامانه بازیابی انتخاب شده‌اند تولید می‌کند.

روش	مزیت	ضعف در صورت استفاده تنها	نقش در طراحی
BM25	دقت بالا برای واژگان و شماره‌های دقیق	درک ضعیف‌تر از بازیابی معنایی	پوشش تطابق لفظی
برداری	پوشش مشابهت معنایی و عبارات‌های متفاوت	ممکن است ماده ظاهراً مشابه اما نادرست بیاورد	پوشش مفهوم
RRF	ترکیب پایدار دو رتبه‌بندی ناهم‌مقیاس	خودش ارتباط عمیق را نمی‌سنجد	ساخت فهرست کاندیدا
Cross-Encoder	قضاوت دقیق پرسش در برابر متن ماده	هزینه محاسباتی بالاتر	فیلتر و رتبه‌بندی نهایی

جدول ۳ - روش‌های جستجو در پایگاه داده

۳-۴. معماری قسمت تولید پاسخ مبتنی بر بازیابی

پس از انجام فرایند بازیابی و انتخاب مقررات مرتبط، مرحله تولید پاسخ آغاز می‌شود. هدف این مرحله آن است که مدل زبانی پاسخ خود را بر اساس اطلاعات حقوقی بازیابی شده تولید کند و وابستگی آن به دانش داخلی مدل در پاسخ‌گویی به پرسش‌های حقوقی کاهش یابد. برای این منظور، در سامانه پیشنهادی از روش تولید تقویت‌شده با بازیابی یا Retrieval-Augmented Generation استفاده شده است.

در طراحی سامانه، نتایج نهایی مرحله بازرتبه‌بندی به عنوان ورودی بخش تولید پاسخ در نظر گرفته می‌شوند. ابتدا اطلاعات مربوط به هر مقرره شامل عنوان سند، شماره مقرره، عنوان و متن آن استخراج شده و توسط Context Builder در قالب یک زمینه متنی ساخت‌یافته قرار می‌گیرند. هر مقرره با یک شناسه مشخص در زمینه قرار داده می‌شود تا مدل زبانی بتواند ارتباط میان اطلاعات موجود و مقررات ارائه‌شده را تشخیص دهد.

پس از ایجاد زمینه حقوقی، پرسش کاربر به همراه زمینه بازیابی‌شده در اختیار مدل زبانی قرار می‌گیرد. برای کنترل رفتار مدل، یک دستورالعمل سیستمی مشخص برای مدل در نظر گرفته شده است. در این دستورالعمل تأکید می‌شود که مدل باید پاسخ خود را تنها بر اساس اطلاعات موجود در زمینه تولید کند و از ایجاد قوانین، مواد، تاریخ‌ها یا سایر اطلاعات حقوقی خارج از زمینه خودداری نماید.

یکی از اصول اصلی طراحی این بخش، جلوگیری از تولید اطلاعات بدون پشتوانه در شرایطی است که منابع بازیابی‌شده ارتباط کافی با پرسش ندارند. در صورتی که هیچ‌یک از مقررات بازیابی‌شده پاسخ پرسش را به صورت مستقیم یا قابل اتکا پشتیبانی نکنند، مدل نباید از دانش عمومی خود برای تکمیل پاسخ استفاده کند و باید ناکافی بودن اطلاعات موجود را به صورت صریح اعلام نماید.

۴. فصل چهارم: پیاده‌سازی سامانه پاسخ‌گویی هوشمند حقوقی

۴-۱. پیاده‌سازی ساختار داده‌های حقوقی

یکی از بخش‌های اصلی سامانه، طراحی ساختاری برای نگهداری اطلاعات حقوقی است. برخلاف ذخیره‌سازی ساده متن قوانین، در این پروژه اسناد حقوقی به صورت ساختاریافته ذخیره می‌شوند تا روابط میان بخش‌های مختلف قانون حفظ شود.

برای این منظور، مدل داده‌ای شامل موجودیت‌هایی مانند سند حقوقی، عناصر ساختاری، مواد قانونی، نسخه‌های مختلف مواد و روابط میان آن‌ها طراحی شده است.

هر سند حقوقی (LegalDocument) می‌تواند شامل مجموعه‌ای از عناصر ساختاری مانند فصل‌ها، بخش‌ها و مواد قانونی باشد. مواد قانونی (LegalProvision) به عنوان واحد اصلی بازیابی اطلاعات در سیستم در نظر گرفته شده‌اند و اطلاعاتی مانند شماره ماده، عنوان، متن و ارتباط آن با سند مربوطه را نگهداری می‌کنند.

همچنین به دلیل تغییرات احتمالی قوانین در طول زمان، امکان نگهداری نسخه‌های مختلف هر ماده فراهم شده است. این موضوع باعث می‌شود سیستم بتواند میان نسخه جاری و نسخه‌های قدیمی یک مقرره تفاوت قائل شود.

۴-۲. پیاده‌سازی فرآیند پردازش و آماده‌سازی داده‌ها

پس از طراحی ساختار داده، مرحله بعدی آماده‌سازی داده‌های حقوقی برای استفاده در سیستم است. در این مرحله، اسناد قانونی دریافت شده، بخش‌بندی شده و به عناصر قابل پردازش تبدیل می‌شوند.

فرآیند پردازش شامل مراحل زیر است:

۱. دریافت متن اسناد حقوقی از منابع مشخص.
۲. تشخیص ساختار سند شامل عنوان، فصل‌ها، بخش‌ها و مواد.
۳. استخراج مواد قانونی به عنوان واحدهای مستقل.
۴. ذخیره اطلاعات استخراج‌شده در پایگاه داده رابطه‌ای.
۵. ایجاد ارتباط میان عناصر مختلف سند.

این مرحله باعث می‌شود متن‌های حقوقی خام به داده‌هایی تبدیل شوند که قابلیت جست‌وجو، تحلیل و بازیابی هوشمند داشته باشند.

۳-۴. پیاده‌سازی موتور بازیابی اطلاعات

برای بازیابی مواد قانونی مرتبط با پرسش کاربر، از معماری ترکیبی استفاده شده است. این معماری شامل دو مرحله اصلی است:

بازیابی مبتنی بر متن

در مرحله اول، جست‌وجوی متنی برای یافتن مواد قانونی دارای ارتباط مستقیم با کلمات موجود در پرسش انجام می‌شود. این روش برای یافتن تطابق‌های دقیق میان پرسش و متن قوانین کاربرد دارد.

بازیابی معنایی

در مرحله دوم، متن پرسش و مواد قانونی توسط مدل **embedding** به بردارهای عددی تبدیل می‌شوند. سپس با استفاده از شباهت میان بردارها، نزدیک‌ترین مواد قانونی از نظر معنایی استخراج می‌شوند.

بردارهای ایجادشده در پایگاه داده برداری **Milvus** ذخیره شده‌اند و امکان جست‌وجوی سریع میان حجم زیادی از مواد قانونی را فراهم می‌کنند.

ترکیب این دو روش باعث می‌شود سیستم علاوه بر یافتن قوانین دارای کلمات مشابه، توانایی یافتن قوانین مرتبط از نظر مفهوم را نیز داشته باشد.

۴-۴. پیاده‌سازی مرحله بازرتبه‌بندی نتایج

نتایج اولیه بازیابی ممکن است شامل تعداد زیادی ماده قانونی باشد که همه آن‌ها ارتباط یکسانی با پرسش ندارند. به همین دلیل، یک مرحله بازرتبه‌بندی (**Reranking**) پس از بازیابی اولیه در نظر گرفته شده است.

در این مرحله، مدل **Cross Encoder** پرسش کاربر و هر نتیجه بازیابی‌شده را به صورت هم‌زمان بررسی کرده و میزان ارتباط آن‌ها را محاسبه می‌کند.

پس از محاسبه امتیاز ارتباط، نتایج بر اساس میزان شباهت مرتب شده و تنها مرتبط‌ترین مواد برای مرحله تولید پاسخ ارسال می‌شوند.

این مرحله باعث کاهش نتایج نامرتبط و افزایش دقت پاسخ نهایی سیستم می‌شود.

۴-۵. پیاده‌سازی ماژول تولید پاسخ

در مرحله نهایی، اطلاعات بازیابی شده به همراه پرسش کاربر در اختیار مدل زبانی بزرگ قرار می‌گیرد. ماژول تولید پاسخ وظیفه دارد:

۱. پرسش کاربر را دریافت کند.
۲. منابع حقوقی مرتبط را دریافت نماید.
۳. پاسخ را تنها بر اساس منابع ارائه شده تولید کند.
۴. از ایجاد اطلاعات خارج از منابع جلوگیری کند.

برای کاهش خطاهای مدل زبانی، قوانین مشخصی در قالب **Prompt** طراحی شده است که مدل را محدود می‌کند تا تنها از محتوای بازیابی شده استفاده کرده و در صورت نبود اطلاعات کافی، عدم وجود منبع مناسب را اعلام کند.

مراحل کامل اجرای پروژه در فایل **readme.md** داخل **github** قرار داده شده است.

۶. فصل پنجم: جمع بندی

۵-۱. نتیجه گیری

در این پروژه، یک سامانه هوشمند برای پردازش، بازیابی و پاسخ‌گویی به پرسش‌های حقوقی به زبان فارسی طراحی و پیاده‌سازی شد. هدف اصلی پروژه، ایجاد سامانه‌ای بود که بتواند به جای اتکا صرف به دانش داخلی مدل زبانی، پاسخ‌های خود را بر اساس منابع و مقررات حقوقی موجود تولید کند.

برای دستیابی به این هدف، ابتدا ساختاری برای استخراج و سازمان‌دهی اسناد حقوقی طراحی شد و اطلاعات مربوط به اسناد، عناصر ساختاری، مقررات و نسخه‌های مختلف آن‌ها در یک پایگاه داده ساخت‌یافته ذخیره گردید. سپس برای بازیابی اطلاعات مرتبط با پرسش کاربر، از ترکیب روش‌های بازیابی واژگانی و معنایی استفاده شد. روش **BM25** برای تطابق دقیق واژه‌ها و عبارات و روش **embedding** برای تشخیص ارتباط معنایی میان پرسش و مقررات مورد استفاده قرار گرفت. نتایج این دو روش با استفاده از **RRF** ترکیب شده و سپس توسط مدل بازرتبه‌بندی ارزیابی شدند.

در مرحله تولید پاسخ نیز از معماری **Retrieval-Augmented Generation** استفاده شد. در این معماری، مقررات منتخب به عنوان زمینه در اختیار مدل زبانی قرار می‌گیرند و مدل موظف است پاسخ خود را بر اساس اطلاعات بازیابی شده تولید کند. همچنین برای کاهش احتمال تولید اطلاعات نادرست، در طراحی سامانه تأکید شده است که مدل در صورت ناکافی بودن منابع موجود، از ارائه اطلاعات خارج از زمینه خودداری کند.

در مجموع، پیاده‌سازی انجام‌شده نشان می‌دهد که ترکیب ساختاردهی داده‌های حقوقی، روش‌های مختلف بازیابی اطلاعات، بازرتبه‌بندی و مدل‌های زبانی بزرگ می‌تواند چارچوب مناسبی برای توسعه سامانه‌های پاسخ‌گویی حقوقی فارسی فراهم کند. سامانه ایجادشده علاوه بر فراهم کردن امکان پاسخ‌گویی مبتنی بر منابع حقوقی، زیرساخت لازم برای توسعه قابلیت‌های پیشرفته‌تر در حوزه تحلیل قوانین و اسناد حقوقی را نیز فراهم می‌کند.

۵-۲. محدودیت‌ها

در این پروژه، یک سامانه هوشمند برای پردازش، بازیابی و پاسخ‌گویی به پرسش‌های حقوقی به زبان فارسی طراحی و پیاده‌سازی شد. هدف اصلی پروژه، ایجاد سامانه‌ای بود که بتواند به جای اتکا صرف به دانش داخلی مدل زبانی، پاسخ‌های خود را بر اساس منابع و مقررات حقوقی موجود تولید کند.

برای دستیابی به این هدف، ابتدا ساختاری برای استخراج و سازمان‌دهی اسناد حقوقی طراحی شد و اطلاعات مربوط به اسناد، عناصر ساختاری، مقررات و نسخه‌های مختلف آن‌ها در یک پایگاه داده ساخت‌یافته ذخیره گردید. سپس برای بازیابی اطلاعات مرتبط با پرسش کاربر، از ترکیب روش‌های بازیابی واژگانی و معنایی استفاده شد. روش BM25 برای تطابق دقیق واژه‌ها و عبارات و روش embedding برای تشخیص ارتباط معنایی میان پرسش و مقررات مورد استفاده قرار گرفت. نتایج این دو روش با استفاده از RRF ترکیب شده و سپس توسط مدل بازرتبه‌بندی ارزیابی شدند.

در مرحله تولید پاسخ نیز از معماری Retrieval-Augmented Generation استفاده شد. در این معماری، مقررات منتخب به عنوان زمینه در اختیار مدل زبانی قرار می‌گیرند و مدل موظف است پاسخ خود را بر اساس اطلاعات بازیابی‌شده تولید کند. همچنین برای کاهش احتمال تولید اطلاعات نادرست، در طراحی سامانه تأکید شده است که مدل در صورت ناکافی بودن منابع موجود، از ارائه اطلاعات خارج از زمینه خودداری کند.

در مجموع، پیاده‌سازی انجام‌شده نشان می‌دهد که ترکیب ساختاردهی داده‌های حقوقی، روش‌های مختلف بازیابی اطلاعات، بازرتبه‌بندی و مدل‌های زبانی بزرگ می‌تواند چارچوب مناسبی برای توسعه سامانه‌های پاسخ‌گویی حقوقی فارسی فراهم کند. سامانه ایجادشده علاوه بر فراهم کردن امکان پاسخ‌گویی مبتنی بر منابع حقوقی، زیرساخت لازم برای توسعه قابلیت‌های پیشرفته‌تر در حوزه تحلیل قوانین و اسناد حقوقی را نیز فراهم می‌کند.

۶. منابع و مراجع

Cui, J., Li, Z., Yan, Y., Chen, B., & Yuan, L. (2023). ChatLaw: Open-Source Legal [۱]
Large Language Model with Integrated External Knowledge Bases. arXiv preprint

- .Chen, W., et al. (2024). Large Language Models in Law: A Survey. AI Open [۲]
- Chalkidis, I., Fergadiotis, M., Malakasiotis, P., Aletras, N., & Androutsopoulos, I. [۳]
(2020). LEGAL-BERT: The Muppets Straight Out of Law School. Findings of the
.Association for Computational Linguistics: EMNLP 2020
- Chalkidis, I., Jana, A., Hartung, D., Bommarito, M., Aletras, N., Katz, D. M., & [۴]
Søgaard, A. (2022). LexGLUE: A Benchmark Dataset for Legal Language
Understanding in English. Proceedings of the 60th Annual Meeting of the
.Association for Computational Linguistics
- Bokaei, Z., Magdy, W., & Webber, B. (2026). Farsi Natural Language Processing: [۵]
.A Survey. Information Processing & Management
- Safavi, T., & Kouhbanani, A. (2018). Hazm: A Python Library for Persian Natural [۶]
.Language Processing
- Manning, C. D., Raghavan, P., & Schütze, H. (2008). Introduction to Information [۷]
.Retrieval. Cambridge University Press
- Robertson, S., & Zaragoza, H. (2009). The Probabilistic Relevance Framework: [۸]
BM25 and Beyond. Foundations and Trends in Information Retrieval, 3(4), 333–
.389
- Cormack, G. V., Clarke, C. L. A., & Büttcher, S. (2009). Reciprocal Rank Fusion [۹]
Outperforms Condorcet and Individual Rank Learning Methods. Proceedings of the
32nd International ACM SIGIR Conference on Research and Development in
.Information Retrieval, 758–759
- Reimers, N., & Gurevych, I. (2019). Sentence-BERT: Sentence Embeddings [۱۰]
using Siamese BERT-Networks. Proceedings of the 2019 Conference on Empirical
Methods in Natural Language Processing and the 9th International Joint
.Conference on Natural Language Processing
- Sentence Transformers Documentation. Cross-Encoder and Reranking [۱۱]
.Documentation
- HeydariAI. Persian Embeddings. Hugging Face Model Repository. Available at: [۱۲]
<https://huggingface.co/heydariAI/persian-embeddings>
- Aghadavoud Jolfaei, S. (2025). Reranker XLM-RoBERTa-Large for Persian [۱۳]
Scientific Retrieval. Hugging Face Model Repository. Available at:
<https://huggingface.co/safora/reranker-xlm-roberta-large>
- .Milvus Documentation. Vector Database Documentation [۱۴]

[۱۵] Django Documentation. Django Web Framework Documentation

[۱۶] PostgreSQL Documentation. PostgreSQL Documentation

[۱۷] Roshan Research. Hazm: Persian Natural Language Processing Toolkit. GitHub

Repository. Available at: <https://github.com/roshan-research/hazm>

[۱۸] نظامات. مجموعه تنقیحی قوانین و مقررات. /Available at: <https://nezamat.ir>

[۱۹] سامانه ملی قوانین و مقررات جمهوری اسلامی ایران. پایگاه قوانین و مقررات کشور.

[۲۰] روزنامه رسمی جمهوری اسلامی ایران. پایگاه رسمی انتشار قوانین و مقررات کشور..